# XML

M. KASSE

Université Alioune DIOP de BAMBEY

youssou.kasse@uadb.edu.sn

**D2AW**

**2014 2015**

# PLAN

- **Présentation de XML**
- **La structure des documents XML**
- **La validation des documents XML: DTD et XMLSchema**
- **L'extraction de fragments XML: XPath, Xquery**
- **La transformation des documents XML : XSLT**

# Chapitre 1

# Présentation de XML

# Présentation de XML

- Le langage XML (*eXtended Markup Language)* est une spécification du W3C depuis février 1998, mais les premiers travaux autour de XML débutent dès 1996.

- XML n'est pas une nouveauté mais une succession d'un ensemble de technologies tels que le SGML, HTML …

- Pour donner un aperçu rapide de XML, on peut le définir tel un langage (ou une méthode) permettant de structurer des données en employant un format texte comme support

# Présentation de XML

- Pourquoi XML ?
  - HTML n'est pas extensible, il ne peut pas répondre aux besoins spécifiques de tous les domaines (mathématiques, chimie, musique, astronomie...) et ne définit plus le contenu du document
  - SGML, qui permettrait de définir de nouveaux langages de balisage spécifiques, est complexe pour le web

# Présentation de XML

- Le XML, en lui-même, ne fait rien !
  - Alors que le Html a été conçu pour afficher de l'information, le XML a été créé pour structurer de l'information. Il ne fait rien d'autre !
  - Voici un exemple de XML.

```
<?xml version="1.0"?>
<demoXML>
    <message>Voici du XML
   </message>
</demoXML>
```

***Ce qui donne avec IE***



# Présentation de XML

- Quelques applications :
  - ✓**MathML** *Mathematical Markup Language* notation mathématique sur le web
  - ✓**AML** *Astronomical Markup Language* langage décrivant les différents types de données utilisées en astronomie.
  - ✓**CML** *Chemical Markup Language* pour la publication Internet des formules chimiques, de molécules
  - ✓**VML** *Vector Markup Language* langage de balisage d'information graphique vectorielle
  - ✓**SMIL** *Synchronized Multimedia Integration Language* pour la création multimédia, il spécifie comment et quand des éléments multimédia peuvent apparaître dans une page web
  - ✓**WML** *Wireless Markup Language* le langage de balisage pour l'internet mobile

# Présentation de XML

```
<?xml version="1.0" encoding="iso-8859-1"?>
<xhtml:html xmlns:xhtml="http://www.w3.org/1999/xhtml">
    <xhtml:body>
        <math   display="block"
        xmlns="http://www.w3.org/1998/Math/MathML">
            <msup>
                <mrow>
                    <mo>(</mo>
                    <mi>a</mi>
                    <mo>+</mo>
                    <mi>b</mi>
                    <mo>)</mo>
                </mrow>
                <mn>2</mn>
            </msup>
        </math>
    </xhtml:body>
</xhtml:html>
```

**Ici on décrit l'expression : (a+b)^2**

# Présentation de XML

- XML repose sur le balisage d'un flux de texte, comme HTML.
- La différence fondamentale entre les deux langages est qu'il n'existe aucune limitation quant aux balises de XML !
- En fait, chacun peut inventer ses propres balises.
- Une balise (tag) se symbolise de la façon suivante : **<nom de balise>** : on parle dans ce cas de balises ouvrante.
- Pour fermer une balise, on utilise le format suivant : **</nom de balise>.**

# Présentation de XML

- Dans l'exemple précédent <demoXML> et <message> sont des exemples de balises (tags).
- Les balises sont des chaînes de caractères Unicode encadrées par les caractères « <« et « > ».
- Entre une balise de début et la balise de fin correspondante, on peut trouver du texte ou d'autres balises.

# Présentation de XML

- Pour schématiser, un fichier XML est composé de deux sortes de texte Unicode :
  - **Du texte de balisage**. Les balises sont simplement une technique d'écriture pour représenter la notion conceptuelle d'élément.
  - **Des données textuelles** séparées par des balises. Les données textuelles sont les contenus des éléments.
- Lorsque des éléments sont imbriqués dans d'autres éléments, ils génèrent des structures arborescentes.

# Présentation de XML

- Pour comprendre un document XML, il est nécessaire de disposer d'un répertoire des balises utilisées dans ce document, ainsi que d'une **grammaire** décrivant la structuration des balises entre elles.
- Ces documents indispensables à la compréhension métier des fichiers XML sont les DTD (**DocumentType Definition**) ou les **schémas XML**.
- XML est souvent défini comme un « langage de balises sémantiques ».

# Principes du langage XML

- Les documents XML sont destinés essentiellement à être traités par des programmes informatiques appelés **processeurs XML**.
- Les documents XML doivent être facilement lisibles par l'homme
- Un document XML doit obligatoirement être **bien formé** : obéir à la spécification XML
  - Chaque élément doit avoir une balise de début et la balise de fin correspondante
  - Les balises doivent être correctement imbriquées entre elles
  - Tout document XML doit avoir un et un seul **élément racine** : un élément qui contient tous les autres
  - Les valeurs associées aux attributs doivent être encadrées par les délimiteurs « ‘‘ » ou « ‘ »

# Principes du langage XML

- Les **processeurs XML** sont des programmes permettant de vérifier que des documents XML sont bien formés.
- Ils traitent le contenu des éléments de manière déterministe. On parle aussi d'analyseurs syntaxiques XML (**XML parsers**)
- Le fonctionnement d'un processeur XML peut être décrit de la manière suivante :
  - À la rencontre d'une balise de début, entrer dans l'état de traitement de cette balise
  - À la rencontre de la balise de fin correspondante, sortir de cet état et revenir à l'état précédent
  - S'il n'y a pas d'état précédent, alors on vient de quitter l'état de traitement de l'élément racine : par conséquent, le document est bien formé.
  - Si une balise de fin ne correspond pas à l'état en cours, le document est mal formé

# Principes du langage XML

- Document XML bien formé (vs valide)
  - Il ne doit exister qu'une seule balise racine
  - Toute balise ouverte doit être fermée
  - Les noms des balises doivent commencer par une lettre ou "_", les autres caractères peuvent être des chiffres, des lettres, "_", "." ou "-".
  - Les noms des balises ne doivent pas commencer par xml
  - pas de balise male imbriquée
- **ATTENTION:** XML est key sensitive

# EXEMPLES

1

```
<?xml version="1.0" encoding="ISO-8859-1"?>
<personne>
      <nom>
      <prenom>
      </nom>
      </prenom>
<personne>
```

**Ko : Mauvaise imbrication**

5

```
<?xml version="1.0" encoding="ISO-8859-1"?>
<personne>
```

**Ko : Balise non fermée**

```
<?xml version="1.0" encoding="ISO-8859-1"?>
<personne/>
```

**Ok : Élément vide**

2

```
<?xml version="1.0" encoding="ISO-8859-1"?>
<personne>
</Personne>
```

**Ko : Personne différent de personne**

4

3

```
<?xml version="1.0" encoding="ISO-8859-1"?>
<xmlmine>
</xmlmine>
```

**Ko : Pas de nom de balise commençant par xml**