XML

M. KASSE

Université Alioune DIOP de BAMBEY

youssou.kasse@uadb.edu.sn

D2AW

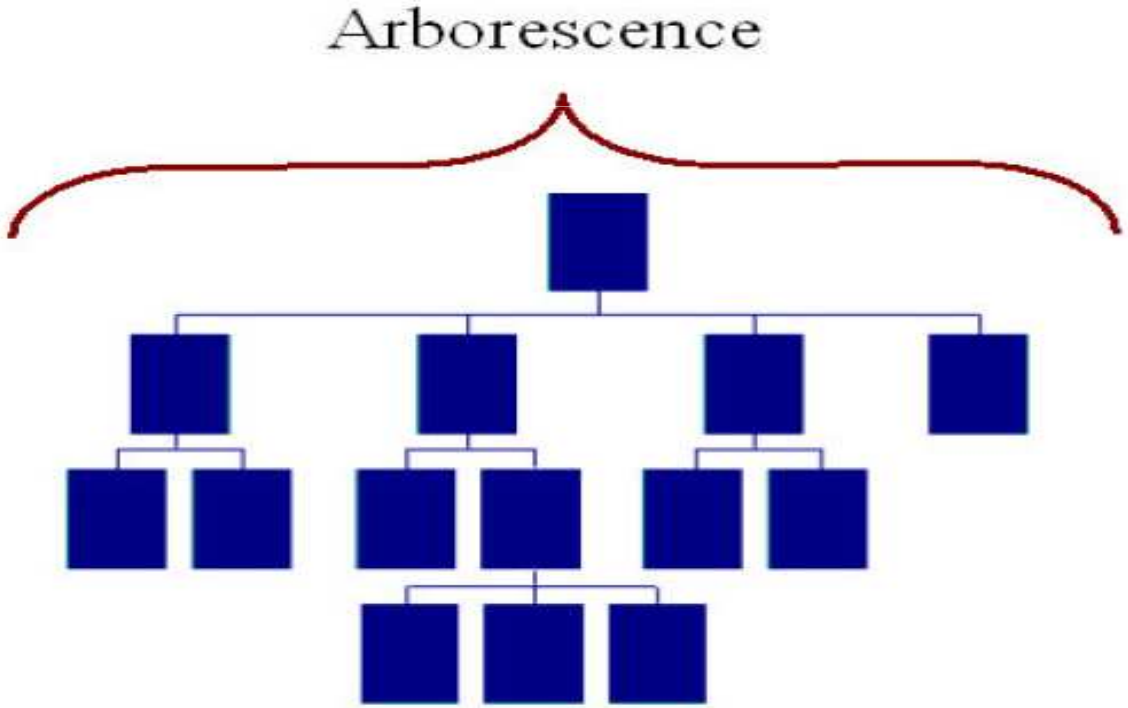
2014 2015

Chapitre 2

Documents XML : Structure Logique et Structure Physique

Structure des documents XML

- La structure logique d'un document XML est une arborescence: structure hiérarchique et ordonnée



Structure des documents XML

- La structure logique d'un document XML est une arborescence d'informations obtenue par un processeur XML à partir d'un contenu physique constitué d'une simple suite linéaire de caractères Unicode.
- Du point de vue logique, un document XML est composé :
  - D'éléments constituant la grammaire d'organisation ;
  - De textes constituant les données ;
  - éventuellement
    - De déclarations contenues dans un préambule,
    - De commentaires,
    - D'instructions de traitement.

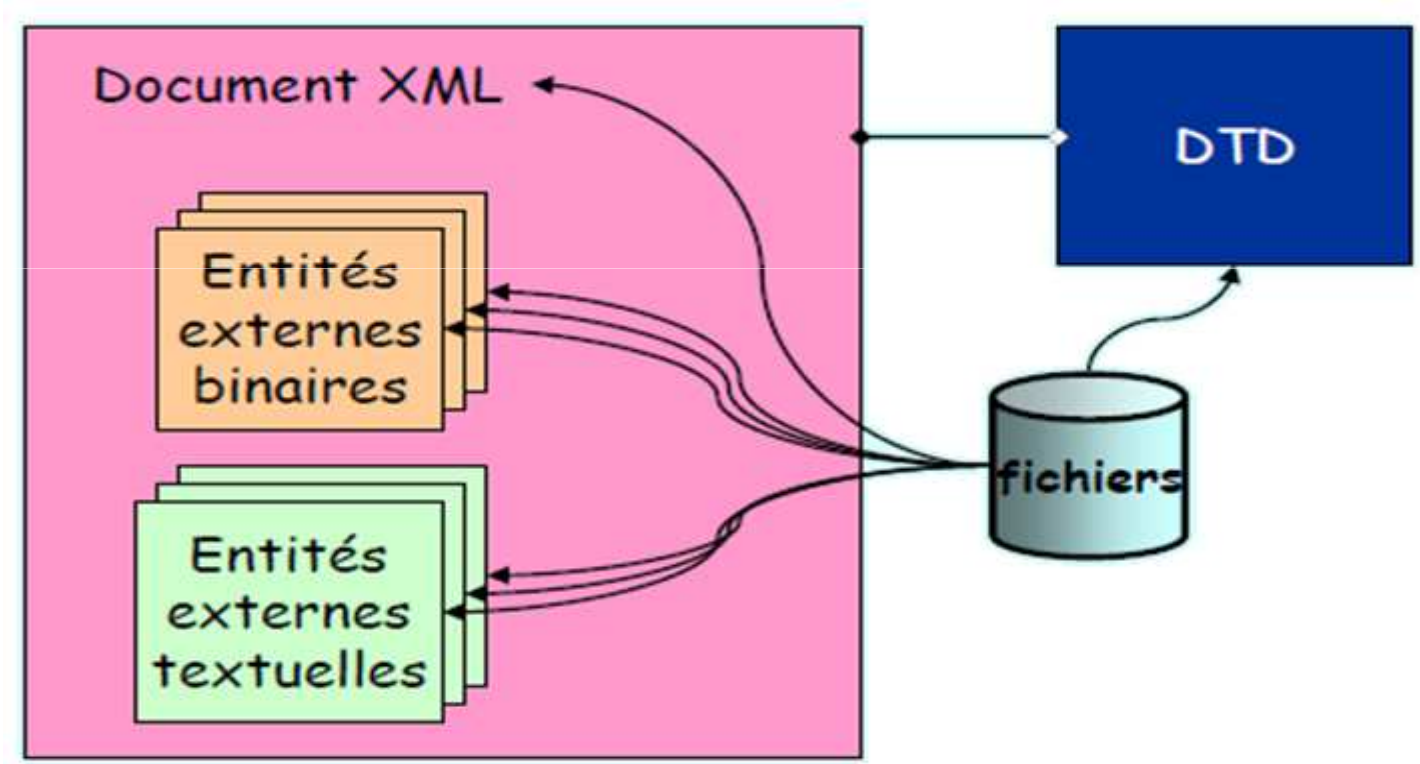
Structure des documents XML

- Un document XML peut exister physiquement d'un seul bloc mais dépend le plus souvent de l'assemblage de plusieurs unités physiques existant séparément et appelées entités.

- Les entités peuvent être schématisées comme des fichiers provenant de différents moyens de stockage situés à différents emplacements

- Chaque entité peut elle-même appeler d'autres entités

Structure des documents XML

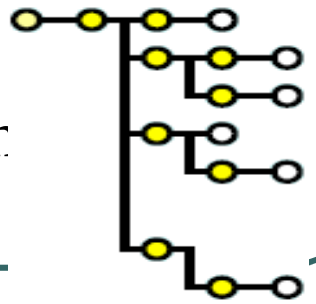


Structure des documents XML

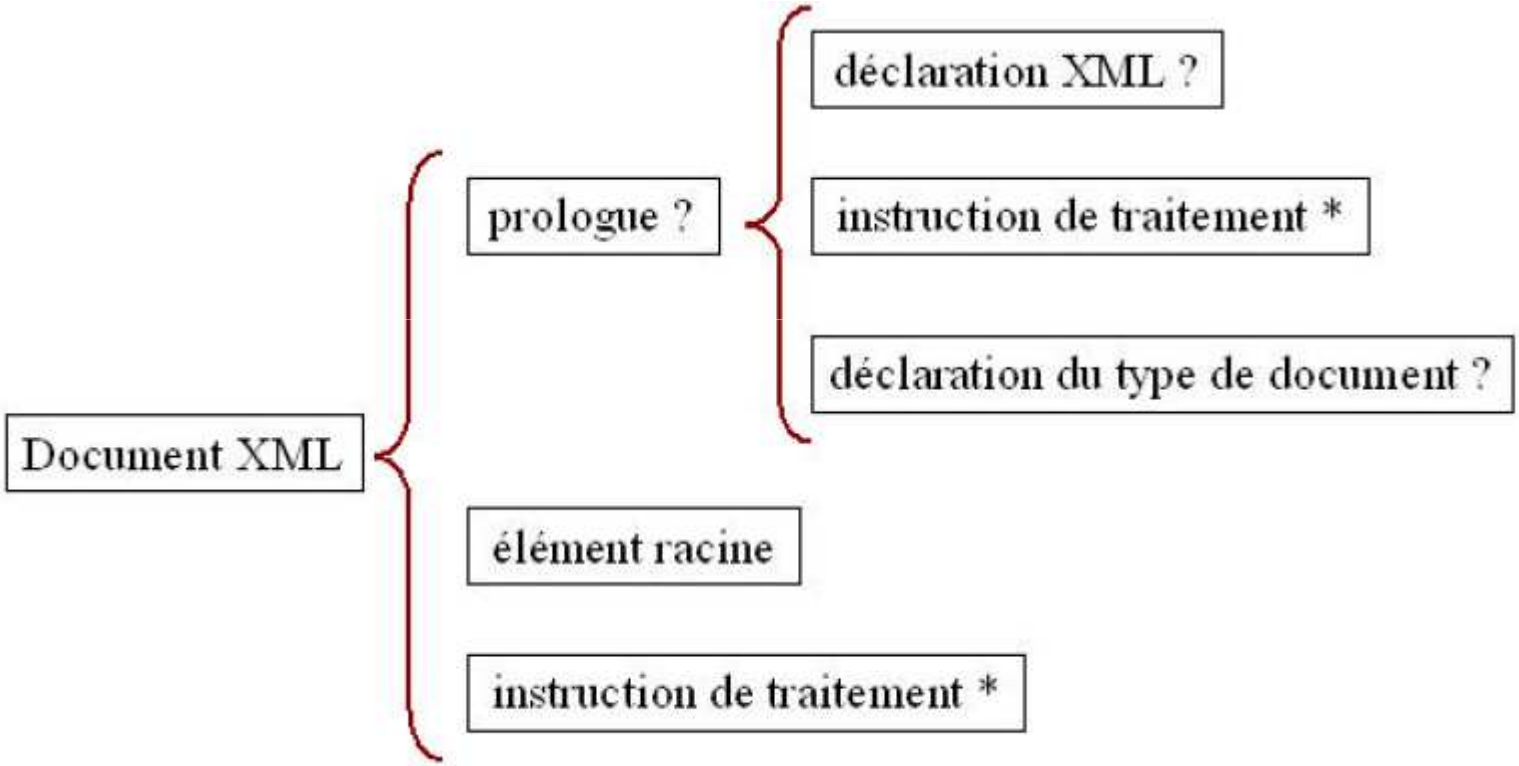
- La structure physique d'un document XML
  - Séquence de caractères "à plat"
  - Spécifie l'encodage caractère
  - Spécifie le découpage en fichiers
  - Peut contenir des caractères non significatifs (indentations)

```
<?xml version="1.0" ?>
- <demoXML>
    <message>Voici du XML</message>
  </demoXML>
```

- La structure logique d'un document XML
  - Une arborescence d'informations obtenue par ur XML à partir du contenu physique



Structure des documents XML



Préambule et déclarations

- une déclaration XML
- **<?xml version='1.0" encoding="ISO-8859-1" ?>**
- Le **préambule** (prolog) s'il est présent, précède le texte de balisage et les données textuelles d'un document. Il contient des déclarations qui peuvent être les suivantes :

  - La **déclaration XML**. Elle n'est pas obligatoire. La spécification XML précise cependant qu'elle devrait être placée au début d'un document XML. Si elle est présente, elle doit apparaître en premier

Préambule et déclarations

- une déclaration de type de document

<!DOCTYPE bulletin_météo SYSTEM "meteo.dtd" [ ]>

- **La déclaration de type de document** (Document Type Declaration : différente de la DTD). Elle n'est obligatoire que pour la validation. Si elle est présente, elle doit se trouver dans le préambule et suivre la déclaration XML. La déclaration de type de document permet de référencer et/ou définir localement deux sortes d'entités :
  - Des définitions de type de document (DTD) contenant des déclarations de balisage ;
  - Des entités (autres que des DTD).

Préambule et déclarations

- La déclaration XML débute par « **<?xml** » et se termine par « **?>** ». Elle fournit trois informations sous la forme de pseudo-attributs.
- **version** : cet attribut est obligatoire quand la déclaration XML est présente **<?xml version=‘‘1.0’’ ?>**
- **encoding** : cet attribut indique le type de codage que doivent utiliser les processeurs XML afin de traduire des octets en caractères Unicode à la réception d’un document, ou de transformer des caractères Unicode en données binaires pour le transport.
- Il permet à des applications de se comprendre.
- **<?xml version=‘‘1.0’’ encoding=‘‘ISO-8859-1’’ ?>**

Préambule et déclarations

- **standalone** : cet attribut indique la nature autonome ou non d'un document.

- Un document est déclaré non-autonome lorsque l'entité document qui le représente est dépendante de déclarations de balisage externes

<?xml version=‘‘1.0’’ encoding=‘‘UTF8’’standalone=‘‘no’’ ?>

Structure des documents XML

- **La déclaration XML :** encoding

Norme	Correspondance
UTF-8	Jeu de caractères universel sur 8 bits
UTF-16	Jeu de caractères universel sur 16 bits
Norme	**Correspondance**
ISO-8859-1	Latin 1 – Langues d'Europe de l'ouest et d'Amérique latine
ISO-8859-2	Latin 2 – Langues d'Europe centrale et Slaves
ISO-8859-3	Latin 3 – Langues Espéranto, Galicienne, Maltaise et Turc
ISO-8859-4	Latin 4 – Langues Estonienne, Lettonne et Lithuanienne
ISO-8859-5	Langue Cyrilliques
ISO-8859-6	Langue Arabe
ISO-8859-7	Langue Grecque
ISO-8859-8	Langue Hébraïque
ISO-8859-9	Latin 5 – Langue Turc
ISO-8859-10	Latin 6 – Langues Groenlandaises et Lapones

Commentaires et instructions de traitement

- Les commentaires peuvent être placés dans un fichier XML ou un fichier DTD :
- <!-- commentaire -->
- Instructions de traitement (Processing Instructions)
  - Instructions spéciales pour les applications qui manipulent les documents XML : <?cible arg1 arg2 …?>
  - cible : nom de l'application
  - arg1, arg2 : arguments passées à l'application
  - <?xml-stylesheet type="text/css" href="style.css" ?>
  - Cette instruction indique au navigateur d'afficher les données XML en appliquant la feuille de style : "style.css"

Structure physique : Entités

- Un document XML est physiquement découpé en entités
- Qu'est-ce q'une entité ?
  - Une entité est un fragment nommé de document
  - Ces sont des « raccourcis » vers des portions de documents allant du caractère au document complet
- Ces entités doivent être définies dans l'en-tête du document XML, ou dans la DTD, et peuvent être référencées à une ou plusieurs reprises dans le document.

Structure physique : Entités

- Pourquoi utiliser des entités ?
  - Pour gagner du temps dans les mises à jour
  - Pour mémoriser des caractères particuliers ou des phrases fréquentes

Entité XML définie dans le document

- Une telle entité sert en général d'abbréviation pour des informations répétitives ou qui peuvent être modifiées en bloc:

```
<?xml version="1.0"?>
<!DOCTYPE démo [
  <!ELEMENT démo (#PCDATA|important)>
  <!ELEMENT important (#PCDATA)>
  <!ENTITY cie "Les aliments de Dakar SA">
  <!ENTITY imp "<important>Attention!</important>">
]>
<démo>
  &cie;
  &imp;
</démo>
```

- Ce document déclare les entités **cie** et **imp**, et les utilise. Pour ce faire, on utilise une balise formée du caractère "&", suivi du nom de l'entité, suivi du caractère ";".

Entité XML définie dans le document

- Le document précédent est équivalent au suivant:

```
<?xml version="1.0"?>
<!DOCTYPE démo [
    <!ELEMENT démo (#PCDATA|important)>
    <!ELEMENT important (#PCDATA)>
    <!ENTITY cie "Les aliments de Dakar SA">
    <!ENTITY imp "<important>Attention!</important>">
 ]>
<démo>
    Les aliments de Dakar SA
    <important>Attention!</important>
</démo>
```

- Un parseur XML fournira à une application exactement la même information dans les deux cas.

Entité XML définie à l'externe

- **Entité XML définie à l'externe**
- Les entités définies à l'extérieur des documents sont utilisées de la même façon mais sont déclarées ainsi :

```
<?xml version="1.0"?>
<!DOCTYPE doc [
   <!ENTITY chap1 SYSTEM "../chapitres/chap1.xml">
   <!ENTITY chap2 SYSTEM "../chapitres/chap2.xml">
]>
<doc>
  &chap1;
  &chap2;
</doc>
```

- Dans cet exemple, on suppose que les fichiers "chap1.xml" et "chap2.xml" contiennent les chapitres marqués en XML.

Types d'entités

- **On distingue :**
  - **entités prédéfinies**
  - **entités caractères**
  - **entités générales qui sont des fragments de l'élément du document,**
  - **entités paramètres qui sont des fragments de DTD.**

Déclaration d'une entité

- **Déclaration d'une entité paramètre :**
  - **interne**
    - <!ENTITY% *nom "entité*">
  - **externe**
    - <!ENTITY% *nom* SYSTEM *nom du fichier contenant l'entité*>

Déclaration d'une entité

- **Déclaration d'une entité générale :**
  - **interne**
    - <!ENTITY *nom* "*entité*">
  - **externe**
    - <!ENTITY *nom* SYSTEM "*nom du fichier contenant l'entité*">

Déclaration d'une entité

- **Par exemple :**
- <!ENTITY % identificateur ID #REQUIRED>

- <!ENTITY ref "refuge">

- <!ENTITY monentite SYSTEM "mon_site/entites.**xml**">

Référence à une entité

- Une référence à une entité paramètre a la forme suivante :

  %nom;

  - Par exemple :
  - <!ATTLIST renvoi cible %identificateur;>
  - au lieu de :
  - <!ATTLIST renvoi cible ID #REQUIRED>

Référence à une entité

- **Une référence à une entité générale a la forme suivante :**

  &nom;

  - **Par exemple :**
  - <para>S'élever au-dessus du &ref; des Drayères en direction est. Suivre…</para>
  - **au lieu de :**
  - <para>S'élever au-dessus du refuge des Drayères en direction est. Suivre…</para>

Entités caractères

- Un caractère non disponible sur la station de travail peut être représenté par son code Unicode en décimal ou en hexadécimal, sous la forme d'une référence a une entité :
  - &#*code décimal*;
  - &#x*code hexadécimal*;
- **Par exemple :**
  - & caractère & (son code ascii est 38 et hexadécimal 26)
  - Φ lettre grecque Φ
  - © s'écrit © ou ©

Entités prédéfinies

- Les caractères < > & ' " qui sont des délimiteurs XML peuvent être remplacés dans un texte par une référence à une entité prédéfinie.
- Ces entités sont les suivantes :
  - < référe le caractère <
  - > référe le caractère >
  - & référe le caractère &
  - ' référe le caractère '
  - " référe le caractère "

Espaces de noms

- L'importation d'éléments ou d'attributs contenus dans des entités externes peut entraîner des conflits de noms
- Ces conflits peuvent être évités en définissant des espaces de noms
- Les espaces de noms en XML, c'est un moyen
  - d'éviter les conflits de noms.
  - d'identifier de façon universelle les noms utilisés dans les documents

Espaces de noms

- Les documents XML sont eux-mêmes des espaces de noms :
  - Les noms d'éléments doivent être uniques dans un document ;
  - De plus, chaque élément est un espace de noms pour ses attributs

Concept d'espace de noms

- Le concept d'espace de noms (ou espace de nommage) correspond à la notion de **collections de noms** dans laquelle on puise pour parler ou écrire.
- Notion analogue à celle d'un vocabulaire : les noms existent, et l'on s'en sert à volonté pour exprimer ce que l'on a envie ou besoin de dire.

Concept d'espace de noms

- Chaque instance de document contient zéro ou plusieurs instances de noms.
- Une instance de nom est locale (c'est-àdire qualifiée par aucun espace de noms) ou est identifié par un et un seul espace de noms référencé par sa partie préfixe.
- Les instances de noms qualifiées ont ainsi un « **contexte** » permettant d'éviter les conflits de noms.

Concept d'espace de noms

- Une instance de document XML déclare zéro, une ou plusieurs instances d'espaces de noms.
- Une même instance d'espaces de noms peut être déclarée par zéro, une ou plusieurs instances de documents XML.
- Les instances d'espaces de noms qui qualifient les noms d'un document XML doivent avoir été déclarées dans cette instance de document.
- Une instance d'espace de noms est une URI.

Notion d'URI (Uniform Resource Identifiers)

- Permettent d'identifier les espaces de noms
- Doivent être persistantes et universellement uniques
- Structure des URI
- Structure générique **[procédure:]information-spécifique[#fragment]**
- des modèles conformes à cette structure : les URL et les URN

Notion d'URI

- URL (Uniform Resource Locator)
- Exemple simple d'URI
- Basé sur une structure hiérarchique
- Structure d'une URL
  - La partie procédure correspond à un **protocole**
  - L'information-spécifique indique un **nom d'hôte**

Notion d'URI

- URN (Uniform Resource Name)
- Nom indépendant d'un quelconque mode d'accès
- Exemple
- Un numéro de carte étudiant, un ISBN d'un livre ou la référence à une partie de la documentation d'un projet
  - **urn:numéro:222-77777-4**
  - **urn:ISBN:2-1177-1048-9**
  - **urn:projet-K822-AXF556.specs.chp04.eth**

Déclaration d'un espace de noms

- La déclaration d'un espace de noms et de son préfixe associé consiste à insérer dans la balise ouvrante d'un élément contenant des noms (d'éléments ou d'attributs) issus de cet espace, l'attribut :
- xmlns:*préfixe*="*URI de l'espace de noms*"
- On peut déclarer un espace de noms par défaut par l'attribut :
- *xmlns="URI de l'espace de noms"*

Exemple d’espace de noms

```
<?xml version="1.0" encoding="UTF-8" ?>
<dossier_scolaire>
<dénomination xmlns="http://uadb.edu.sn/etudiants">
Abdou Gaye
</dénomination>
<dénomination xmlns="http://uadb.edu.sn/diplomes">
Mastère
</dénomination>
<dénomination xmlns="http://uadb.edu.sn/matieres">
Informatique
</dénomination>
</dossier_scolaire>
```

Exemple d'espace de noms

- Supposons que
  - l'URI « monSite/dtdLivre.xml » contienne une DTD pour la description de livres et
  - que les éléments auteur, editeur et annee du guide « Itinéraires skieurs » soient conformes à ces définitions, la description de ce guide pourrait être la suivante :

```
<guide xmlns:livre="monSite/dtdLivre.xml">
<livre:titre>Itinéraires skieurs dans la Vallée de la Clarée </livre:titre>
<livre:auteur>Jean-Gabriel Ravary</livre:auteur>
<livre:editeur>Le Polygraphe</livre:editeur>
<livre:annee>1991</livre:annee>
…
<vallon>
<nom>Vallon des Muandes</nom>
…
</guide>
```