XML

M. KASSE

Université Alioune DIOP de BAMBEY

youssou.kasse@uadb.edu.sn

D2AW

2014 2015

Chapitre 3

La validation des documents XML: DTD

Structure physique : DTD

- Une DTD (Document Type Definition) est une sorte d'entité contenant une description formelle de la structure et du vocabulaire (noms de type d'éléments et noms d'attributs) d'un document.

- La spécification XML définit complètement l'écriture des DTD,

- Mais une DTD n'est pas elle-même un document XML

Structure physique : DTD

- Un processeur validateur lit la DTD avant de lire le document.
- Une DTD
  - Permet de définir le "vocabulaire" et la structure qui seront utilisés dans le document XML
  - Grammaire du langage dont les phrases sont des documents XML (instances)
  - Peut être mise dans un fichier et être appelée dans le document XML

Structure physique : DTD

- La DTD utilise la déclaration DOCTYPE qui référencie des déclarations soit internes ou externes
- **DTD interne** :
  - Les déclarations de la DTD sont placés dans le DOCTYPE après la déclaration XML
  - L'attribut standalone a la valeur "yes" <?xml version="1.0" standalone="yes">
  - <!DOCTYPE **document** [déclarations]> **<document >** ... **</document >**
  - document : nom de la balise racine du document déclaré,
  - déclarations : déclarations d'éléments, d'attributs et d'entités…

Structure physique : DTD

- **DTD externe** : permet d'inclure des documents XML identifiés par une URI
- <!DOCTYPE document SYSTEM "uri">
- Les déclarations sont placés dans un fichier séparé
- L'attribut standalone a la valeur "no"
- <!DOCTYPE document SYSTEM "http://uadb.edu.sn/document.dtd">

Structure physique : DTD

- <!DOCTYPE document (PUBLIC "identifiant_public" "url"?)>
- PUBLIC est utilisé lorsque la DTD est une norme ou qu'elle est enregistrée sous forme de norme ISO par l'auteur

Structure physique : DTD

- **DTD externe**
  - Les déclarations sont placés dans un fichier séparé portant l'extension .dtd

    <!DOCTYPE document (SYSTEM "uri")>
  - L'attribut **standalone** a la valeur **"no"**

    <?xml version="1.0" standalone="no" >

    <!DOCTYPE document SYSTEM "http://ucad.sn/document.dtd">

    <document > ... </document >
  - un chemin relatif :

    <?xml version="1.0" standalone="no" >

    <!DOCTYPE document SYSTEM "document.dtd">

    <document > ... </document >

Contrainte sur la DTD EXTERNE

- Il peut contenir un prologue
- Pas de référence à une DTD
- Il doit être bien formé

Structure physique : DTD

- Déclaration de listes d'attributs
  - <!ATTLIST Nom_élément Nom_attribut type_attribut défaut>
  - <!ATTLIST document nd (1|2|3) "1">
- Type d'attributs :
  - CDATA : chaîne de caractères prise telle quelle
  - ID ou IDREF : renvoi dans le document
  - ENTITY ou ENTITIES : entité externe non XML
  - NMTOKEN (s): noms symboliques formés de caractères alphanumériques sans espace (plusieurs NMTOKEN

Structure physique : DTD

- Déclaration d'un élément :
- <!ELEMENT balise valeur>
- Décrit une balise **balise** qui fera partie du vocabulaire
- ordre spécifié :
- <!ELEMENT balise (val1, val2, val3)>
- ordre libre :
- <!ELEMENT balise (val1 | val2 | val3)>
- Indicateur d'occurrence d'un élément
- Contenu textuel déclaré comme PCDATA (parseable character data)

Structure physique : DTD

- Opérateurs d'occurrence

Notations	**Exemples**
(a, b) séquence	(nom, prenom, rue, ville)
(a | b) liste de choix	(oui | non)
a? élément optionnel [0,1]	(nom, prenom?, rue, ville)
a* élément répétitif [0,N]	(produit*, client)
a+ élément répétitif [1,N]	(produit*, vendeur+)

Structure physique : DTD

- Valeur par défaut des attributs:
  - #REQUIRED : attribut obligatoirement présent et valeur spécifié par le créateur de l'instance
  - #IMPLIED : présence de l'attribut facultative
  - #FIXED "Valeur" : l'attribut prend toujours cette valeur

Structure physique : DTD

- Données dans un élément : simple
  - <!ELEMENT Donnees (#PCDATA)>
  - les données sont constituées par un flot de caractères
- Modèle mixte : complexe
  - <!ELEMENT mixte (#PCDATA | val1 | val2)*>
  - dans cet exemple l'élément mixte est composé de données et d'éléments

Quelques exemples

- Contenu libre :
  - <!ELEMENT libre ANY>
- Élément vide :
  - <!ELEMENT vide EMPTY>
- Attributs pour un élément :
  - <!ATTLIST balise [attribut type #mode [valeur]]>
- Définition de la liste des attributs pour une balise
  - <!ATTLIST enseignant nom CDATA #REQUIRED prenom CDATA #IMPLIED>
  - <!ATTLIST adresse ville CDATA #FIXED "Dakar">

Quelques exemples

- Liens hypertextuels internes : ID ou IDREF
- Dans la DTD
  - <!ELEMENT SECTION (#PCDATA|xref)*>
  - <!ATTLIST SECTION TARGET ID #IMPLIED>
  - <!ELEMENT xref EMPTY>
  - <!ATTLIST xref ref IDREF #REQUIRED>
- Dans l'instance
  - <SECTION TARGET="cible"> contenu </SECTION>
  - <SECTION> référence à la section
  - <xref ref="cible"/>
  - </SECTION>

Structure physique : Une DTD pour un Address Book

```
<?xml version="1.0" encoding="UTF-8"?>
<!ELEMENT addressBook (person)+>
 <!ELEMENT person (name, email*, link)>
<!ATTLIST person id ID #REQUIRED
                        gender (male|female) #IMPLIED>
<!ELEMENT name (#PCDATA|family|given)*>
<!ELEMENT family (#PCDATA)>
<!ELEMENT given (#PCDATA)>
<!ELEMENT email (#PCDATA)>
<!ELEMENT link EMPTY>
<!ATTLIST link manager IDREF #IMPLIED subordinates IDREFS
#IMPLIED>
```

Exemple d'un XML valide par rapport aux règles dans la DTD précédente

```
<!DOCTYPE addressBook SYSTEM "ab.dtd">
<addressBook>
   <person id="B.WALLACE" gender="male">
      <name>
         <family>Wallace</family> <given>Bob</given>
      </name>
     <email>bwallace@megacorp.com</email>
    <link manager="C.TUTTLE"/>
</person>
<person id="C.TUTTLE" gender="female">
    <name>
        <family>Tuttle</family> <given>Claire</given>
    </name>
    <email>ctuttle@megacorp.com</email>
    <link subordinates="B.WALLACE"/>
</person>
</addressBook>
```

Exemple DTD

- Supposons, La description des livres d'une librairie
  - Stocker des informations sur titre, auteur, éditeur, prix
  - C'est possible d'avoir plusieurs auteurs pour un livre
  - Le prix est optionnel
  - Les prix seront classés par catégorie
  - cat1 pour les livres dont le prix est inférieur à 020€
  - cat2 pour les livres dont le prix est entre 20€ et 40€
  - cat3 pour les livres dont le prix est supérieur à 40€

Définir en <cat1></cat1>, <cat2></cat2>, <cat3></cat3>

Exemple DTD

- Nœuds racine est librairie
- <!DOCTYPE **librairie** [

  … instructions …
-]>

Exemple DTD

- Dans notre librairie, on peut avoir 0 ou plusieurs livres
- <!DOCTYPE **librairie** [

  <!ELEMENT librairie (livre*)>
-]>

Exemple DTD

- L'information d'un livre (titre, auteur, éditeur, prix)
- <!DOCTYPE **librairie** [

  <!ELEMENT librairie (livre*)>

  <!ELEMENT livre(titre, auteur, éditeur, prix)>
-]>

Exemple DTD

- Un livre peut avoir un ou plusieurs auteurs
- <!DOCTYPE **librairie** [

  <!ELEMENT librairie (livre*)>

  <!ELEMENT livre(titre, auteur+, éditeur, prix)>
-]>

Exemple DTD

- Le prix d'un livre est optionnel
- <!DOCTYPE **librairie** [

  <!ELEMENT librairie (livre*)>

  <!ELEMENT livre(titre, auteur+, éditeur, prix**?**)>
-]>

Exemple DTD

- Titre, auteur et éditeur sont stockés comme chaîne de caractère.
- <!DOCTYPE **librairie** [

  <!ELEMENT librairie (livre*)>

  <!ELEMENT livre(titre, auteur+, éditeur, prix**?**)>

  <!ELEMENT titre (#PCDATA)>

  <!ELEMENT auteur (#PCDATA)>

  <!ELEMENT éditeur (#PCDATA)>
-]>

Exemple DTD

- Prix sont stockés soit cat1, cat2 ou cat3
- <!DOCTYPE **librairie** [

  <!ELEMENT librairie (livre*)>

  <!ELEMENT livre(titre, auteur+, éditeur, prix**?**)>

  <!ELEMENT titre (#PCDATA)>

  <!ELEMENT auteur (#PCDATA)>

  <!ELEMENT éditeur (#PCDATA)>

  <!ELEMENT prix (cat1 |cat2 | cat3)>
-]>

Exemple DTD

- Cat1, cat2, cat3 sont des éléments qui sont valeurs
- <!DOCTYPE **librairie** [

<!ELEMENT librairie (livre*)>

<!ELEMENT livre(titre, auteur+, éditeur, prix**?**)>

<!ELEMENT titre (#PCDATA)>

<!ELEMENT auteur (#PCDATA)>

<!ELEMENT éditeur (#PCDATA)>

<!ELEMENT prix (cat1 |cat2 | cat3)>

<!ELEMENT cat1 EMPTY)>

<!ELEMENT cat2 EMPTY) >

<!ELEMENT cat3 EMPTY)>

-]>

DTD avec attribut

- Le prix d'un livre est optionnel et c'est l'attribut de l'élément livre qui a des valeurs, soit cat1, cat2 ou cat 3
- <!DOCTYPE **librairie** [

  <!ELEMENT librairie (livre*)>

  <!ELEMENT livre(titre, auteur+, éditeur)>

  <!ATTLIST livre prix(cat1|cat2|cat3) #IMPLIED>

]>